## 形式语言与自动机理论

### 正则表达式

丁效 xding@ir.hit.edu.cn

> 计算学部 哈尔滨工业大学

> > 2023年2月

#### 正则表达式

- 正则表达式
  - 语言的运算
  - 正则表达式的递归定义
  - 运算符的优先级
  - 正则表达式示例
- 有穷自动机和正则表达式
- 正则表达式的代数定律

#### 正则表达式

- 有穷自动机
  - 通过机器装置描述正则语言
  - 用计算机编写相应算法, 易于实现
- 正则表达式
  - 通过表达式描述正则语言, 代数表示方法, 使用方便
  - 应用广泛
    - grep 工具 (Global Regular Expression and Print)
    - Emacs / Vim 文本编辑器
    - lex / flex 词法分析器
    - 各种程序设计语言 Python / Perl / Haskull / ···

#### 语言的运算

#### 设L和M是两个语言,那么

并 
$$L \cup M = \{w \mid w \in L \ \vec{x} \ w \in M\}$$
 连接  $L \cdot M = \{w \mid w = xy, \ x \in L \ \exists \ y \in M\}$  幂  $L^0 = \{\varepsilon\}$   $L^1 = L$   $L^n = L^{n-1} \cdot L$  克林闭包  $L^* = \bigcup_{i=0}^{\infty} L^i$ 

例 1. 若有语言 
$$L$$
 = {0,11} 和  $M$  = { $arepsilon$ , 001}, 那么  $L \cup M$  =  $L^0$  =  $LM$  =  $L^1$  =  $L^2$  =

例 2. 对于空语言 ∅

 $\forall n \geq 1, \quad \emptyset^n =$ 

Ø\* =

四则运算表达式的递归定义:

- 任何数都是四则运算表达式;
- ② 如果 a 和 b 是四则运算表达式, 那么

a+b, a-b,  $a \times b$ ,  $a \div b \times 10^{\circ}$  (a)

都是四则运算表达式。

#### 正则表达式的递归定义

#### 定义

如果 Σ 为字母表, 则 Σ 上的正则表达式递归定义为:

- Ø 是一个正则表达式,表示空语言;
   E 是一个正则表达式,表示语言 {ε};
   ∀α ∈ Σ, α 是一个正则表达式,表示语言 {α};
- ② 如果正则表达式  $\mathbf{r}$  和  $\mathbf{s}$  分别表示语言 R 和 S, 那么

$$r+s$$
,  $rs$ ,  $r^*$  和  $(r)$ 

都是正则表达式, 分别表示语言

 $R \cup S$ ,  $R \cdot S$ ,  $R^*$   $\Pi$  R.

#### 运算符的优先级

正则表达式中三种运算以及括号的优先级:

- 首先,"括号"优先级最高;
- 2 其次, "星"运算: r\*;
- 3 然后, "连接"运算: rs, r·s;
- 4 最后, "加"最低: r+s, r∪s;

例 3.

$$1 + 01^* = 1 + (0(1^*))$$

$$\neq 1 + (01)^*$$

$$\neq (1 + 01)^*$$

$$\neq (1 + 0)1^*$$

#### 正则表达式示例

例4.

E	$\mathbf{L}(E)$
$\mathbf{a} + \mathbf{b}$	$\mathbf{L}(\mathbf{a}) \cup \mathbf{L}(\mathbf{b}) = \{a\} \cup \{b\} = \{a, b\}$
bb	$\mathbf{L}(\mathbf{b}) \cdot \mathbf{L}(\mathbf{b}) = \{b\} \cdot \{b\} = \{bb\}$
$(\mathbf{a} + \mathbf{b})(\mathbf{a} + \mathbf{b})$	$\{a,b\}\{a,b\} = \{aa,ab,ba,bb\}$
$(\mathbf{a} + \mathbf{b})^* (\mathbf{a} + \mathbf{b}\mathbf{b})$	$\{a,b\}^*\{a,bb\} = \{a,b\}^*\{a\} \cup \{a,b\}^*\{bb\} = \{w \in \{a,b\}^* \mid w \ \text{仅以}a \ \text{或}bb \ \text{结尾.}\}$
1+(01)*	$\{1, \varepsilon, 01, 0101, 010101, \ldots\}$
$(0+1)^*01(0+1)^*$	$\{x01y \mid x, y \in \{0,1\}^*\}$

例 5. 给出正则表达式  $(aa)^*(bb)^*b$  定义的语言.

例 5. 给出正则表达式 (aa)\*(bb)\*b 定义的语言.

$$\mathbf{L}((\mathbf{a}\mathbf{a})^*(\mathbf{b}\mathbf{b})^*\mathbf{b}) = \mathbf{L}((\mathbf{a}\mathbf{a})^*) \cdot \mathbf{L}((\mathbf{b}\mathbf{b})^*) \cdot \mathbf{L}(\mathbf{b})$$
$$= (\{a\} \cdot \{a\})^* \cdot (\{b\} \cdot \{b\})^* \cdot \{b\})$$
$$= \{a^2\}^* \cdot \{b^2\}^* \cdot \{b\}$$

 $= \{ a^{2n} \mid n \ge 0 \} \cdot \{ b^{2n} \mid n \ge 0 \} \cdot \{ b \}$ 

 $= \{ a^{2n}b^{2m+1} \mid n \ge 0, m \ge 0 \}$ 

例 6. Design regular expression for  $L = \{w \mid w \text{ consists of 0's and 1's, and the third symbol from the right end is 1.}$ 

$$(0+1)^*1(0+1)(0+1)$$

例 7. Design regular expression for  $L = \{w \mid w \in \{0,1\}^* \text{ and } w \text{ has no pair of consecutive 0's.} \}$ 

$$\mathbf{1}^*(\mathbf{011}^*)^*(\mathbf{0}+arepsilon)$$
 或  $(\mathbf{1}+\mathbf{01})^*(\mathbf{0}+arepsilon)$ 

课堂练习.

Give regular expressions for each of the following languages over  $\Sigma = \{0, 1\}$ .

**1** All strings containing the substring 000.

2 All strings *not* containing the substring 000.

#### 正则表达式

- 正则表达式
- 有穷自动机和正则表达式
  - 由 DFA 到正则表达式, 递归表达式法
  - 由 DFA 到正则表达式, 状态消除法
  - 由正则表达式到  $\varepsilon$ -NFA
- 正则表达式的代数定律

# DFA, NFA, $\varepsilon$ -NFA 和正则表达式的等价性 $\varepsilon$ -NFA $\varepsilon$ -NFA 和正则表达式

#### 由 DFA 到正则表达式, 递归表达式法

定理 3

若  $L = \mathbf{L}(A)$  是某 DFA A 的语言, 那么存在正则表达式 R 满足  $L = \mathbf{L}(R)$ .

#### 由 DFA 到正则表达式, 递归表达式法

#### 定理 3

若  $L = \mathbf{L}(A)$  是某 DFA A 的语言, 那么存在正则表达式 R 满足  $L = \mathbf{L}(R)$ .

证明: 对 DFA A 的状态编号, 令 1 为开始状态, 即

$$A = (\{1,2,\ldots,n\}, \Sigma, \delta, 1, F),$$

设正则表达式  $R_{ij}^{(k)}$  表示从 i 到 j 但中间节点不超过 k 全部路径的字符串集:

$$R_{ij}^{(k)} = \{x \mid \hat{\delta}(i,x) = j, x$$
经过的状态除两端外都不超过  $k \}$ .



那么与  $A = (\{1,2,...,n\}, \Sigma, \delta, 1, F)$  等价的正则表达式为

$$igcup_{j\in F} R_{1j}^{(n)}$$

日递归式为

$$egin{aligned} R_{ij}^{(k)} &= R_{ij}^{(k-1)} + R_{ik}^{(k-1)} ig( R_{kk}^{(k-1)} ig)^* R_{kj}^{(k-1)} \ & & \ R_{ij}^{(0)} &= egin{cases} ig\{ a \ | \ \delta(q_i, a) = q_j \ \} \ \cup \{ arepsilon \} & i 
eq j \end{cases} \end{aligned}$$

下面对 k 归纳, 证明可用以上递归式求得  $R_{ii}^{(k)}$ .

归纳基础: 当  $i \neq j$ , k = 0 时, 即 i 到 j 没经过任何中间节点

没有 i 到 j 的状态转移

$$(i)$$
  $(j)$ 

• 有一个 i 到 j 的状态转移

$$i \longrightarrow j$$
  $R_{ij}^{(0)} = \mathbf{a}$ 

• 有多个 i 到 j 的状态转移

$$R_{ij}^{(0)} = \mathbf{a}_1 + \mathbf{a}_2 + \dots + \mathbf{a}_t$$

 $R_{i,i}^{(0)} = \varnothing$ 

#### 归纳基础 (续): 当 i = j, k = 0 时, 即从 i 到自身没经过任何中间节点

状态 *i* 没有到自己的转移



$$R_{ii}^{(0)} = \boldsymbol{\varepsilon}$$

• 状态 i 有一个到自身的转移  $R_{ii}^{(0)} = \mathbf{a} + \boldsymbol{\varepsilon}$ 

$$n_{ii} - a +$$

状态 *i* 有多个到自身的转移

$$a_t$$

$$R_{ii}^{(0)} = \mathbf{a}_1 + \mathbf{a}_2 + \dots + \mathbf{a}_t + \boldsymbol{\varepsilon}$$

归纳假设: 假设已知  $R_{ij}^{(k-1)}$ ,  $R_{ik}^{(k-1)}$ ,  $R_{kk}^{(k-1)}$  和  $R_{kj}^{(k-1)}$ .

归纳递推: 那么  $R_{ij}^{(k)}$  中全部路径, 可用节点 k 分为两部分

从 i 到 j 不经过 k 的




• 从 *i* 到 *j* 经过 *k* 的

$$(i) \sim \sim (k) \sim \sim (k) \sim (k)$$

$$R_{ij}^{(k)} = R_{ik}^{(k-1)} (R_{kk}^{(k-1)})^* R_{kj}^{(k-1)}$$


因此 
$$R_{ij}^{(k)} = R_{ij}^{(k-1)} + R_{ik}^{(k-1)} (R_{kk}^{(k-1)})^* R_{kj}^{(k-1)}$$
.

例 8. 将如图 DFA 转换为正则表达式.



• 计算  $R_{ij}^{(0)}$ 

例 8. 将如图 DFA 转换为正则表达式.



• 计算  $R_{ij}^{(0)}$ 

$$egin{array}{cccc} R_{ij}^{(k)} & k=0 \ \hline R_{11}^{(0)} & oldsymbol{arepsilon} + \mathbf{1} \ R_{12}^{(0)} & \mathbf{0} \ R_{21}^{(0)} & arnothing \ R_{22}^{(0)} & oldsymbol{arepsilon} + \mathbf{0} + \mathbf{1} \end{array}$$

• 计算 
$$R_{ij}^{(1)} = R_{ij}^{(0)} + R_{i1}^{(0)} (R_{11}^{(0)})^* R_{1j}^{(0)}$$

 $\varepsilon + 0 + 1$ 

$$egin{array}{ccc} R_{ij}^{(k)} & k=0 \ \hline R_{11}^{(0)} & oldsymbol{arepsilon}+\mathbf{1} \end{array}$$

• 计算  $R_{i,i}^{(1)} = R_{i,i}^{(0)} + R_{i,1}^{(0)} (R_{1,i}^{(0)})^* R_{1,i}^{(0)}$ 

k = 1

• 几个基本的化简规则 如果 **r** 和 **s** 是两个正则表达式

$$(\varepsilon + \mathbf{r})^* = \mathbf{r}^*$$
 $(\varepsilon + \mathbf{r})\mathbf{r}^* = \mathbf{r}^*$ 
 $\mathbf{r} + \mathbf{r}\mathbf{s}^* = \mathbf{r}\mathbf{s}^*$ 
 $\varnothing \mathbf{r} = \mathbf{r}\varnothing = \varnothing$ 
 $\varnothing + \mathbf{r} = \mathbf{r} + \varnothing = \mathbf{r}$ 

零元

单位元

• 化简  $R_{ij}^{(1)}$ 

$R_{ij}^{(k)}$	k = 1	化简
$R_{11}^{(1)}$	$(\varepsilon+1)+(\varepsilon+1)(\varepsilon+1)^*(\varepsilon+1)$	1*
$R_{12}^{(1)}$	$0 + (\boldsymbol{\varepsilon} + 1)(\boldsymbol{\varepsilon} + 1)^* 0$	1*0
$R_{21}^{(ar{1})}$	$\varnothing + \varnothing(\varepsilon + 1)^*(\varepsilon + 1)$	Ø
$R_{22}^{\overline{(1)}}$	$\varepsilon + 0 + 1 + \varnothing (\varepsilon + 1)^* 0$	$\varepsilon + 0 + 1$


• 计算 
$$R_{ij}^{(2)} = R_{ij}^{(1)} + R_{i2}^{(1)} (R_{22}^{(1)})^* R_{2j}^{(1)}$$

• 化简  $R_{ij}^{(2)}$ 


• 因只有  $q_2$  是接受状态, 所以该 DFA 正则表达式为

$$R_{12}^{(2)} = \mathbf{1}^* \mathbf{0} (\mathbf{0} + \mathbf{1})^*.$$


例 9. 将如图 DFA 转换为正则表达式.



例 9. 将如图 DFA 转换为正则表达式.



例 9. 将如图 DFA 转换为正则表达式.



仅状态 2 和 3 是接受状态:

$$R_{12}^{(3)} = R_{12}^{(2)} + R_{13}^{(2)} (R_{33}^{(2)})^* R_{32}^{(2)}$$

$$= \mathbf{0}(\mathbf{0}\mathbf{0})^* + \mathbf{0}^* \mathbf{1} (\boldsymbol{\varepsilon} + (\mathbf{0} + \mathbf{1})\mathbf{0}^* \mathbf{1})^* (\mathbf{0} + \mathbf{1})(\mathbf{0}\mathbf{0})^*$$

$$= \mathbf{0}(\mathbf{0}\mathbf{0})^* + \mathbf{0}^* \mathbf{1} ((\mathbf{0} + \mathbf{1})\mathbf{0}^* \mathbf{1})^* (\mathbf{0} + \mathbf{1})(\mathbf{0}\mathbf{0})^*$$

$$R_{13}^{(3)} = R_{13}^{(2)} + R_{13}^{(2)} (R_{33}^{(2)})^* R_{33}^{(2)}$$


$$= \mathbf{0}^* \mathbf{1} + \mathbf{0}^* \mathbf{1} (\boldsymbol{\varepsilon} + (\mathbf{0} + \mathbf{1})\mathbf{0}^* \mathbf{1})^* (\boldsymbol{\varepsilon} + (\mathbf{0} + \mathbf{1})\mathbf{0}^* \mathbf{1})$$

$$= \mathbf{0}^* \mathbf{1} ((\mathbf{0} + \mathbf{1})\mathbf{0}^* \mathbf{1})^*$$

 $R_{12}^{(3)} + R_{13}^{(3)} = \mathbf{0}^* \mathbf{1} ((\mathbf{0} + \mathbf{1}) \mathbf{0}^* \mathbf{1})^* (\varepsilon + (\mathbf{0} + \mathbf{1}) (\mathbf{0} \mathbf{0})^*) + \mathbf{0} (\mathbf{0} \mathbf{0})^*.$ 


#### 分治 (Divide and Conquer) – 普遍且实用的递归求解方式

- ① 将问题实例分解为子问题实例 divide step
- 2 子问题实例可递归解决
- ③ 将子问题实例合并可得到原问题实例 conquer step





#### 由 DFA 到正则表达式, 状态消除法


- 从 DFA 中逐个删除状态
- 用标记了正则表达式的新路径替换被删掉的路径
- 保持"自动机"等价.




• 更一般的情况如图, 若要删除状态 S, 需添加相应路径









① 利用空转移,添加新的开始s和结束状态f:




① 利用空转移,添加新的开始 s 和结束状态 f:



② 消除状态  $q_1$ , 添加路径  $q_0 \rightarrow q_2$  和  $q_2 \rightarrow q_2$ :




② 消除状态  $q_1$ , 添加路径  $q_0 \rightarrow q_2$  和  $q_2 \rightarrow q_2$ :



③ 消除状态  $q_0$ , 添加路径  $s \rightarrow q_2$  和  $q_2 \rightarrow q_2$ :



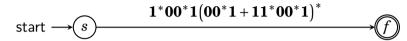
③ 消除状态  $q_0$ , 添加路径  $s \rightarrow q_2$  和  $q_2 \rightarrow q_2$ :



4 消除状态  $q_2$ , 添加路径  $s \rightarrow f$ :

start 
$$\rightarrow$$
  $s$   $1*00*1(00*1+11*00*1)*$ 

4 消除状态  $q_2$ , 添加路径  $s \rightarrow f$ :



5 因此该自动机的正则表达式为

$$1*00*1(00*1+11*00*1)*.$$

# 由正则表达式到有穷自动机

定理 4

正则表达式定义的语言,都可被有穷自动机识别.

#### 由正则表达式构造 $\varepsilon$ -NFA

任何正则表达式  $\mathbf{r}$ , 都存在等价的  $\varepsilon$ -NFA A, 即  $\mathbf{L}(A) = \mathbf{L}(\mathbf{r})$ , 并且 A 满足:

- ① 仅有一个接收状态;
- ② 没有进入开始状态的边;
- 3 没有离开接受状态的边.

证明: 归纳基础:

**1** 对于 Ø, 有 ε-NFA:

对于 ε, 有 ε-NFA:

$$\mathcal{E}$$

**3** ∀a ∈ Σ, 对于 **a**, 有 ε-NFA:

归纳递推: 假设正则表达式  $\mathbf{r}$  和  $\mathbf{s}$  的  $\varepsilon$ -NFA 分别为 R 和 S




那么  $\mathbf{r}+\mathbf{s}$ ,  $\mathbf{rs}$  和  $\mathbf{r}^*$ , 可由 R 和 S 分别构造如下:

- ② 对于  $\mathbf{rs}$ , 有  $\varepsilon$ -NFA: start  $\overset{\circ}{\longrightarrow}$  O R O  $\overset{\varepsilon}{\longrightarrow}$  O S O
- 3 对于  $\mathbf{r}^*$ , 有  $\varepsilon$ -NFA: start  $\rightarrow$   $\varepsilon$

因此任何结构的正则表达式, 都有等价的  $\varepsilon$ -NFA.

例 11. 正则表达式 (0+1)\*1(0+1) 构造为 ε-NFA.



#### 思考题

正则表达式到  $\varepsilon$ -NFA 构造方法中的 3 个限制条件, 都有必要吗?

### 正则表达式

- 正则表达式
- 有穷自动机和正则表达式
- 正则表达式的代数定律
  - 基本的代数定律
  - 发现与验证代数定律



### 正则表达式的代数定律

#### 定义

含有变量的两个正则表达式,如果以任意语言替换其变量,二者所表示的语言仍然相同,则称这两个正则表达式等价.在这样的意义下,正则表达式满足一些代数定律.

• 并运算

$$(L+M)+N=L+(M+N)$$
 结合律   
  $L+M=M+L$  交换律   
  $L+L=L$  幂等律   
  $arnothing+L=L+arnothing=L$  单位元 $arnothing$ 

### 连接运算

$$(LM)N=L(MN)$$
 结合律  $oldsymbol{arepsilon}L=Loldsymbol{arepsilon}=L$  单位元 $oldsymbol{arepsilon}$  零元 $oldsymbol{arepsilon}$  表  $LM
eq ML$ 

分配率

$$L(M+N)=LM+LN$$
 左分配律  $(M+N)L=ML+NL$  右分配律

## • 闭包运算

 $(L^*)^* = L^*$   $\varnothing^* = \varepsilon$   $\varepsilon^* = \varepsilon$ 

 $(\boldsymbol{\varepsilon} + L)^* = L^*$ 

 $L^* = L^+ + \varepsilon$ 

发现与验证正则表达式的代数定律

#### 检验方法

要判断表达式 E 和 F 是否等价, 其中变量为  $L_1, ..., L_n$ :

- ① 将变量替换为具体表达式, 得正则表达式  $\mathbf{r}$  和  $\mathbf{s}$ , 例如替换  $L_i$  为  $\mathbf{a}_i$ ;
  - ② 判断  $\mathbf{L}(\mathbf{r}) \stackrel{?}{=} \mathbf{L}(\mathbf{s})$ , 如果相等则 E = F, 否则  $E \neq F$ .

例 12. 判断 
$$(L+M)^* = (L^*M^*)^*$$
.

• 将 L 和 M 替换为 a 和 b:

- $(\mathbf{a} + \mathbf{b})^* \stackrel{?}{=} (\mathbf{a}^* \mathbf{b}^*)^*;$

- 3 因为  $\mathbf{L}((\mathbf{a}+\mathbf{b})^*) = \mathbf{L}((\mathbf{a}^*\mathbf{b}^*)^*);$

- 4 所以  $(L+M)^* = (L^*M^*)^*$ .

例 13. 判断 L + ML = (L + M)L.

- 2 判断  $\mathbf{a} + \mathbf{ba} \stackrel{?}{=} (\mathbf{a} + \mathbf{b})\mathbf{a}$ ;
- ③ 因为  $aa \notin \mathbf{a} + \mathbf{ba}$  而  $aa \in (\mathbf{a} + \mathbf{b})\mathbf{a}$ ;

- ④ 所以  $\mathbf{a} + \mathbf{b} \mathbf{a} \neq (\mathbf{a} + \mathbf{b}) \mathbf{a}$ ;
- ⑤ 即  $L + ML \neq (L + M)L$ .

- 将 L 和 M 替换为 a 和 b;

### 注意

#### 这种方法仅限于判断正则表达式, 否则可能会发生错误.

例 14. 若用此方法判断  $L \cap M \cap N \stackrel{?}{=} L \cap M$ , 以  $\mathbf{a}, \mathbf{b}, \mathbf{c}$  替换 L, M, N, 有

$$\{a\} \cap \{b\} \cap \{c\} = \varnothing = \{a\} \cap \{b\},\$$

而显然

$$L \cap M \cap N \neq L \cap M$$
.





xding@ir.hit.edu.cn

http://ir.hit.edu.cn/~xding/







